AI 生成 PPT 的最后一公里

面向 AI 生成演示文稿的多层质量审查与按需复核智能体

2026 年 10 月

目录

项目概览 **3**

摘要 **3**

1 项目背景与问题定义 **3**

2 相关工作与差异化定位 **4**

3 系统架构 **6**

4 关键方法 **8**

5 数据与模型方案 **13**

6 课程知识映射 **16**

7 开发路线 **17**

8 风险与已知局限 **18**

9 预期成果 **19**

参考文献 **19**

附录 **A** 统一结论记录的核心字段 **20**

附录 **B** 术语表 **21**

项目概览

项	内容
项目名称	AI 生成 PPT 的最后一公里
项目正式名	基于多层协同检测与按需复核的 PPT 质量审查智能体设计与实现
课程	《智能体设计》期末项目（八周）
项目类型	融合确定性规则、传统机器学习与多模态大模型的智能交互系统
主要用户	使用生成式 AI 制作 PPT 的高校学生、教师、科研与办公人员
核心对象	AI 生成的演示文稿，优先支持可编辑 PPTX
报告日期	2026 年 10 月

摘要

生成式 AI 已能把演示文稿的制作成本从数小时压缩到数分钟，却没有压缩交付前的验收成本。用户拿到一份 AI 生成稿后，仍需逐页核对排版、字体、数据一致性、内容覆盖度，这部分工作被称为” 最后一公里”。

本项目构建一套面向该场景的质量审查系统。系统以可编辑 PPTX 为输入，通过结构解析与页面渲染获得两类证据；以确定性规则处理几何与属性问题，以轻量视觉分类器处理模糊的排版判定，以多模态大模型处理语义级问题；在融合层对多源结论去重、分档、冲突降级，并按置信度决定是否追加一次模型复核；最终输出一份每条结论可回溯到具体元素、每条建议可落到具体操作的风险与优化报告。

系统的技术要点有三：其一，检测路由由缺陷类别表显式给定，而非由编码前缀推断，使” 视觉现象但结构可判” 的缺陷能走低成本路径；其二，将”AI 风格痕迹” 分解为页内的 PTPS 与页间的 HCI 两个可计算指标，明确不输出生成概率；其三，把大模型调用次数作为一等实验指标，与分类别准确率一同报告，用于回答” 哪些缺陷值得调用模型” 这一成本问题。

本报告说明问题边界、系统架构、关键方法、数据与模型方案、课程知识映射、分阶段开发路线，以及已知风险与局限。

1 项目背景与问题定义

1.1 成本被转移，而不是被消除

生成式 AI 对演示文稿的改变，发生在” 从无到有” 这一段：一句话生成一份结构完整的初稿，过去需要数小时，现在需要数分钟。

但交付前的验收并没有随之消失，只是从” 制作” 转移到了” 检查”。一份十五页的 AI 生成稿，用户通常需要完成以下核对：

- 页面排版是否正常，有无文字溢出、元素越界、遮挡压字；
- 视觉风格是否统一，字号层级是否清晰；
- 装饰性元素（图标、emoji、渐变块）是否过多且无信息功能；
- 不同页面之间的关键数据、术语、结论是否一致；
- 生成结果是否满足最初的制作要求，是否覆盖了参考资料的关键内容；
- 在时间有限的前提下，哪几页真正值得改。

这项工作单条不难，但条目多、易遗漏、且难以委托给任何单一工具：规则看不出语义矛盾，大模型说不清元素坐标。

1.2 核心问题

> 如何通过规则、传统机器学习与多模态大模型的协同，把” 逐页人工验收” 压缩为” 读一份报告并处理若干条建议”，同时保证每条结论有据可查、每条建议可以直接执行？

该问题可拆为三个可独立回答的子问题：

子问题	关注点	对应设计
哪些缺陷不需要模型就能判定	成本	分层检测与检测路由
判定一类缺陷需要什么证据	可靠性	证据族与统一记录结构
报告写到什么程度用户才敢照着改	可用性	三级可执行建议

1.3 项目边界

边界不是免责声明，而是设计约束。以下五条在全项目中不可放松：

1. **不判定 PPT 是否由 AI 生成**，不输出任何形式的生成概率或”AI 率”。
2. **不核验内容的事实真伪**，只核验与用户提供的参考资料之间的一致性。
3. **不自动修改用户文件**。系统给出定位、数值与操作路径，修改由用户执行。
4. **不在缺少证据时给出确定结论**。证据不足即标记为待人工核实。
5. **不宣称具备完全自主的规划能力**。自主性仅体现在” 按需复核” 这一处，且有成本上限。

第一条需要展开一点：判断” 是否由 AI 生成” 在技术上要求一个以”AI 生成样本 vs 人工样本” 为基线的判别模型，需要两类各数百份的标注数据。本项目不具备该条件，也不认为这是用户真正关心的问题——用户关心的是” 这页做得像不像模板套出来的”，而不是” 它的作者是谁”。

2 相关工作与差异化定位

2.1 已有工作

工作	做了什么	与本项目的关系
SlideAudit [1]	2,400 张带设计缺陷标注的幻灯片图像（约 600 原始 + 1,800 变体）；评测多个多模态模型识别缺陷的能力	实验一的唯一监督数据来源；其报告的低 F1 是” 单一大模型不足” 的直接论据
PPTEval [2]	随 PPTAgent 一并提出，用大模型从内容、设计、连贯性三个维度为生成结果打 1–5 分	只给分数，不定位到元素，建议不可执行
PresentBench [3]	238 个 PPT 生成任务，每个任务配平均 54 条二元 checklist	借鉴其” 将自然语言要求拆成可核验条目” 的做法，不作为训练数据
AI Is Not Enough [4]	用启发式从视图层级提取属性，结合设计规范 RAG 与大模型判定界面合规性	最接近的先例，证明” 规则 + 大模型” 的混合路线可行

引用编号对应文末参考文献。需要说明的是,SlideAudit 的缺陷标签分为 `design_deficiency_category` 与 `design_deficiency` 两级，本项目不预设其取值与本项目编码的对应关系，映射须在数据核查阶段逐条比对方可确定（见 5.3）。

2.2 差异化定位

SlideAudit 的结论值得单独强调：作者用多个大模型、多种提示策略识别幻灯片设计缺陷，报告的 F1 仅为 0.331 至 0.655，并在摘要中指出模型难以准确定位设计缺陷。这一结果同时构成两件事——它是本项目” 必须分层” 的论据，也意味着” 让多模态模型审 PPT” 这件事已有人做过。

因此本项目的差异不能建立在” 我做了分层框架” 上。可辩护的差异只有三处，且都能用指标证明：

第一，把成本作为一等指标。现有工作报告的是准确率，很少回答” 哪些缺陷值得调用大模型”。本项目将调用次数与 token 消耗与分类别准确率并列报告，绘制成本—效果曲线。

第二，证据强制绑定。每条结论必须携带至少一条可回溯的证据引用（结构坐标、渲染区域或要求条目编号），空证据的记录在数据结构层面不允许存在。由此可以统计” 无依据断言比例” 这一指标。

第三，落在可编辑 PPTX 的结构证据上。SlideAudit 提供的坐标是从图像反推的，不是原生结构；因此在其上无法验证” 规则层” 的价值。本项目以可编辑 PPTX 为主对象，才能讨论” 结构证据让哪些判断变便宜”。

3 系统架构

3.1 总体分层

系统分为六层，前四层在本地执行，第五层按需调用，第六层呈现结果。

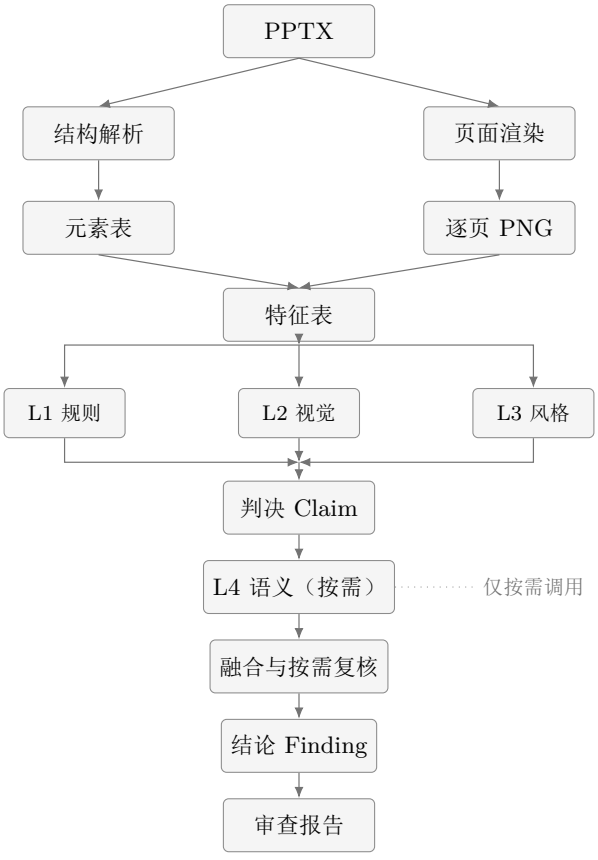
层	名称	主要职责	是否调用模型
L0	输入与预处理	PPTX 解析、页面渲染、文字与图像特征提取	否
L1	规则检测	几何、字号、越界、页数、装饰计数	否
L2	机器学习检测	针对模糊排版判定的视觉分类器	否（本地推理）
L3	风格分析	页内 PTPS、页间 HCI	否
L4	语义与要求核验	跨页一致性、图文关系、参考资料覆盖	是
L5	调度、融合与报告	路由、复核、去重、分档、报告生成	视复核而定

L0 与 L1 的处理单元是 PPTX 对象，L2 与 L3 的处理单元是渲染图与页级特征，L4 的处理单元是页面文本与图像，L5 的处理单元是结论记录。

这一划分有一条物理依据：**不同的缺陷能在不同证据上被判定**。文字是否越界只需读 XML 坐标，留白是否失衡需要看渲染图，两个数字是否矛盾需要理解语义。分层不是设计偏好，而是证据可得性的直接结果。

3.2 数据流

一次完整审查的数据流如下：



关键点：所有检测器**先输出” 判决” 而非” 结论”**。判决包含” 存在” 与” 不存在” 两种取值，只有” 存在” 的判决在融合后转为结论。这样做的原因见 4.6 节。

3.3 可独立运行的模块原则

各检测模块互不依赖，任一模块失效不影响其余模块出结论。这条原则的工程意义在于：即使分类器性能不理想、参考资料检索未完成，基础审查与按需复核流程仍可完整演示。它同时是开发路线的组织依据（见第 7 节）。

4 关键方法

4.1 缺陷体系与证据族

缺陷按**现象族**分为四类，命名前缀供报告组织与用户阅读使用：

前缀	族	判定所需的最小证据	典型检测层
S-	结构	PPTX 对象的几何、属性、层级关系	L1
V-	视觉	页面渲染图像的统计特征	L2
M-	语义	文本含义、图文关系、跨页逻辑	L4
R-	要求	用户原始要求或参考资料与结果的比对	L4

编码前缀表达” 这是什么问题”，不表达” 该由谁检测”。二者通常一致，但允许例外：例如” 视觉层次弱” 属视觉现象，但其最小证据是字号属性，不需要渲染图，因此路由到 L1。这条解耦规则避免了实现阶段用 `code[0]` 推断路由所带来的隐性错误。

4.2 检测路由

路由由缺陷类别表显式给定，不由前缀推断。下表为首批实现的缺陷：

编码	名称	族	首选层	批次
S-OVERSHOOT	元素越界	S	L1	首批
S-TEXT-OVERFLOW	文字溢出	S	L1	首批
S-FONT-FALLBACK	字体替换	S	L1	首批
S-PAGECOUNT	页数超限	S	L1	首批
S-DECO-COUNT	装饰元素过量	S	L1	首批
V-WHITESPACE	留白失衡	V	L2	首批
V-TEMPLATE-REPEAT	布局模板化	V	L2	首批

编码	名称	族	首选层	批次
V-HIERARCHY	视觉层次弱	V	**L1**	二批
M-CROSSPAGE	跨页不一致	M	L4	首批
R-CONTENT-MISS	要求内容缺失	R	L4	首批

这张表同时是成本论证的骨架：结构族占比越高，“全部交给大模型” 越不经济。该比例需在真实样本上统计，不得先验假定。

4.3 PTPS：单页模板化特征分

PTPS（Per-slide Template Pattern Score）衡量**单页**在多大程度上呈现模板化生产特征，取值 0 至 100，越高越模板化。

$$\mathrm{PTPS} = 100 \times (0.4A + 0.3T + 0.3D)$$

分项	含义	计算
A 对齐规整度	元素边缘落在 12 列栅格上的比例	对齐元素数 ÷ 元素总数
T 类型单调度	元素类型分布的集中程度	$1 - H(p)/\log K$，H 为类型分布熵
D 装饰密度	装饰性元素占比	装饰元素数 ÷ 元素总数

“装饰性元素” 的操作定义需要前置说明，否则不可复现：满足以下任一条件的形状计为装饰——无文本内容、面积占比小于 0.5%、形状类型为基本图形或图标且不承载数据。该定义是工程口径，须在报告中标注，并允许按场景调整。

4.3.1 分数的语义边界

PTPS 高分既不表示” 质量差”，也不表示” 由 AI 生成”。这一点必须在定义处写死，否则指标会被误读。

指标测的是结构规律性，不是设计质量。规范的企业品牌模板、咨询公司模板、学术会议模板，恰恰以栅格统一、版式类型少、留白规整为设计目标，因此会同时得到高 PTPS。这不是误判，而是定义使然——若把这类文件判为” 有缺陷”，错的是判据，不是模板。

由此产生三条实现约束：

1. **PTPS 与 HCI 不进入风险等级，不作为 Finding 的一种。**它们与结论清单并列展示，属描述性指标，不参与” 先改哪一页” 的排序。
2. **不触发按需复核。**复核的对象是” 某条结论是否成立”，而不是” 某个分数是否偏高”；对指标本身再问一次模型，只会得到一句无依据的附和。

3. **界面只写” 结构规律性”，不写”AI 味”**。同一屏内固定给出一句说明：模板化程度高不等于质量差，规范的品牌模板同样会得高分。

指标本身的效度可用一个廉价检查代替：若定义成立，企业模板与 AI 生成稿应同时落在高分区，而杂志式排版、手绘风格的稿件应显著更低。若三类样本的分布无法区分，说明分项只测到了”元素多少”，需要重设而非调参。

4.4 HCI：整份同质化指数

HCI（Homogeneity and Cliché Index）衡量**整份文稿内部**的重复程度，取值 0 至 100。

$$\mathrm{HCI} = 100 \times (0.5R_{\mathrm{adj}} + 0.3R_{\mathrm{global}} + 0.2(1 - V_{\mathrm{type}}))$$

分项	含义	计算
R_{adj} 相邻重复	相邻页布局特征余弦相似度超阈值的页对比例	超阈页对数 ÷ 相邻页对数
R_{global} 全局重复	任意两页超阈相似的比例	超阈页对数 ÷ 全部页对数
V_{type} 版式多样性	不同版式的数量占比	版式簇数 ÷ 页数

计算前置条件为页数不少于 8。少于 8 页不计算，因为页间重复需要足够的页对才能成立；这是硬约束而非保守设定。

阈值（相似度 0.92）、权重（0.5/0.3/0.2）与归一化参数均为工程默认值，未经数据校准，报告中须标注。

4.5 PTPS 与 HCI 的分工

两个指标容易混淆，必须在定义上分开，否则会重复计数同一现象。

PTPS 回答” 这一页像不像模板做出来的”，HCI 回答” 整份是不是同一个模板反复用”。前者是页内量，后者是页间量，二者可以独立变化：

情形	PTPS	HCI	解释
每页都精工细作但版式相同	低	高	单页质量好，整份单调
单页随手堆砌但每页都不同	低	低	谈不上模板化，只是粗糙
单页高度规整但版式各异	高	低	模板化生产，但选了多种版式
单页规整且版式一致	高	高	典型的批量生成特征

按此划分，PTPS 的三个分项均为页内量，HCI 的三个分项均为页间量，不存在重叠。这一划分相对前期文档做了收窄：装饰密度归入 PTPS，HCI 不再包含页内项。

两个指标既不构成来源判定，也不构成质量判定。

- 不构成来源判定：人工制作的模板同样可以得到高分。指标衡量的是作品自身的结构规律性，不是作者的归属。
- 不构成质量判定：规范的品牌模板以统一栅格与稳定版式为设计目标，会同时得到高 PTPS 与高 HCI，但它属于好设计。若把它读成” 缺陷”，错在判据。
- 因此二者只作描述性呈现，不进入风险分级，也不进入按需复核的触发条件（理由见 4.3.1）。

4.6 判决与结论分离：为什么需要两层

所有检测器先输出 `Claim`（判决），再由融合层生成 `Finding`（结论）。这一层看似多余，实则不可或缺：

其一，冲突检测需要” 否定” 这一侧。若检测器只记录” 发现了什么”，那么” 规则判定越界、视觉模型判定不存在” 这句最关键的分歧永远无法表达——因为其中的” 不存在” 没有地方存放。有了判决层，冲突可以被显式记录，并直接驱动降级为” 待人工核实”。

其二，覆盖率统计需要它。回答” 某方案在哪些缺陷类别上做了有效判断” 时，需要知道某检测器在该类别上是否给出了判断（无论正负）。只记录正例，覆盖率无法计算，实验二的方案对比也就失去了可比性。

融合后的结论携带以下核心字段：页码、缺陷编码、严重度、状态、置信度及其来源、证据引用、解释、建议、成本与检测器清单。

严重度与状态必须正交。严重度回答” 多要紧”，状态回答” 多确定”。“高严重度 + 待核实” 是完全合法的组合，且恰恰是最需要提醒用户的情形：报出来，但明确说明证据不足。

4.7 按需复核：系统中唯一的自主决策

这是全系统唯一一处真正意义上的” 决策”，也是” 智能体” 三个字唯一站得住的地方。

4.7.1 三种置信度不是同一种量

实现这条决策最容易犯的错，是给所有检测器设同一条阈值。三种来源的 `confidence` 在数学性质上完全不同，直接比较会得到系统性偏差：

来源	输出形态	可否作概率	正确处理
规则	布尔值 + 物理裕度（超出边界多少 pt）	否	裕度接近 0 时视为边界情形，其余直接确定
分类器	概率（未校准）	校准后可	先做 Platt 或 isotonic 校准 [6]，用校准后概率设带，并给出可靠性图

来源	输出形态	可否作概率	正确处理
大模型自评	序数标签（高 / 中 / 低）	不能	只取” 低”“中” 触发复核，不与分类器概率比较

两个具体理由。其一，分类器的原始输出不是概率——SVM 的决策值可落在任意区间，即便逻辑回归的输出也常偏离真实频率，未经校准直接阈值化会系统性偏高或偏低；现代网络的过度自信已被系统验证 [7]。其二，大模型的自评置信度是语言判断而非概率，把它与 0.47 这样的数值比大小，等于把两种量纲混为一谈。

融合层的做法是：**同源内部比较数值，跨源只比较序数**。各来源先映射到” 确定 / 可能 / 待核实” 三档，取最保守者；不拿模型概率与” 中等置信” 直接比大小。

4.7.2 触发条件

触发条件	判定依据	处理
两个检测器结论相反	verdict 冲突	追加一次大模型复核
分类器校准后概率落入 0.5±0.1	校准概率	追加一次复核
大模型自评置信为” 低” 或” 中”	序数标签	追加一次复核
缺陷为最高严重度但仅单源支持	来源计数 $= 1$	追加一次复核
要求类缺陷但用户未提供要求	缺输入	不追加，直接标记待核实

带的具体数值（0.5±0.1）是初始工程默认值，须写进代码常量表并在报告附录列出。**阈值的调整只允许在验证集上做，不允许在测试集上回调**——否则实验三的” 人工复核条数” 会被阈值调优污染。

复核次数、复核命中率（复核后结论被改变的比例）与因此节省的调用数必须计数并纳入报告。否则” 分层省钱” 只是一句宣称。

其余环节的” 调度” 本质是查表：编码确定，路径即确定。项目不将这部分包装为自主规划。

4.8 三级可执行建议

“建议优化排版” 不是可执行建议。本项目将建议分为三级，结构类缺陷要求达到第三级：

- **L1 定位**：哪一页、哪个对象。例：第 7 页右侧第二个文本框。
- **L2 数值**：改什么、改成多少。例：框宽 9.2 cm，可用 8.4 cm，建议缩至 8.2 cm。
- **L3 操作**：在软件中如何操作。例：设置形状格式 → 文本选项 → 关闭” 自动调整”。

实现方式是一张 **缺陷编码 → 建议模板**的映射表，模板中带实测值占位符。这张表同时在项目中承担知识库角色：缺陷类型、所需证据、适用建议三者构成类—属性—关系结构，可序列化为 JSON，必要时转为 RDF。

5 数据与模型方案

5.1 SlideAudit 的构成与划分

SlideAudit 提供约 2,400 张带标注幻灯片图像，其构成需要在使用前核查：初步了解为约 600 张原始页面与约 1,800 个合成变体，即每个原始页面存在数个修改版本。

由此产生一条不可省略的划分要求：**按原始页面分组后再划分训练集与测试集**。若按单张图像随机划分，同一原图的不同变体将跨越两集，模型可能学到" 改图痕迹" 而非缺陷特征，全部指标随之失真。这一条必须在报告中写明。

另需注意：该数据集的元素坐标为图像检测所得，非 PPTX 原生结构。因此它只能支撑视觉层实验，不能用于验证规则层。

5.2 特征方案：几何与视觉混合

初期候选三类缺陷作为监督学习对象：留白分布不均、布局拥挤、字号使用不当。三类能否都成立，不取决于命名，而取决于特征能否从数据集里取出来——这是 5.3 节要裁定的事。先训练、再解释指标为何反常，是这类实验最常见的失败方式。

特征设计上有一项需要预先说明的技术判断：

> **CLIP [5] 特征不适合单独承担几何类缺陷的判定。** CLIP 的预训练目标是图文对齐，其表征偏向语义与风格，对元素间距、越界、面积占比等精确空间关系不敏感。以 CLIP 特征单独训练" 布局拥挤" 分类器，性能很可能低于简单几何统计量。

因此本项目采用**几何特征与 CLIP 特征拼接**的方案，并保留三组消融对比：

特征组	内容	用途
G 几何	元素数、覆盖率、留白四边占比、间距方差、字号分布	直接对应排版属性
C 视觉	CLIP 图像嵌入（降维后）	捕捉整体观感与风格
G+C 拼接	两组拼接	主方案

消融结果本身即是一项可报告的结论：哪一类缺陷更依赖几何证据、哪一类更依赖视觉表征。这比单纯报告一个 F1 更有信息量。

5.3 特征可提取性核查（训练前置）

一条硬性前置：**先证明特征能取出来，再谈训练。** SlideAudit 提供的是渲染图与图像检测得到的元素描述，不是 PPTX 结构，两者能供给的特征并不相同。

首要动作是把 `data/descriptions/` 的字段打印一遍。按仓库说明，每个元素只有三类信息：`type`、`positionAndSize.normalized`、`textContent`（或图像元信息）。据此逐项核对：

计划特征	可得性	依据 / 替代方案
元素数	可直接提取	`elements` 列表长度
元素覆盖率	可直接提取	各 bbox 的 width×height 求和（重叠区会重复计入，须先合并）
留白四边占比	可直接提取	bbox 到画布四边的距离，分边统计
间距方差	可直接提取	元素两两间距的分布
类型分布 / 类型单调度	可直接提取	`type` 字段
栅格对齐度	近似可得	由 bbox 边缘坐标聚类估计，非真实栅格
字号分布	**不可得**	描述中无字号字段；仅能由文本行高像素反推，误差不可控

由此得到三条结论，需在实验开始前落定：

其一，“字号使用不当”应移出实验一。该类别的最小证据是字号属性，图像侧无法可靠还原；而它在本项目中本就由 `V-HIERARCHY` 以”标题字号 ÷ 正文字号”的规则形式呈现——规则不需要训练。硬把它塞进监督学习，只会得到一个无法解释的 F1。

其二，实验一的类别数由 3 收缩为 2。留白失衡与布局拥挤均可由上述几何特征支撑。若核查发现这两类在特征空间上高度重叠（例如留白占比在正负类上的分布几乎重合），则再降一级：不与 SVM 对比，只报告阈值法与逻辑回归，并说明原因。

其三，标签质量也要先查。每条标注带 `has_strong_agreement` 字段，训练与评测应只用强一致样本；弱一致样本单列，用作”标注噪声对指标影响”的分析材料，而不是直接丢弃。`metadata/slideaudit_metadata.csv` 中的 `source_type` 可用于检查来源分布，避免训练集与测试集的来源系统性偏斜。

这一步的产出是一张核查表（特征 × 可得性 × 替代方案），在阶段一结束前完成。**核查不过就换特征或换类别，不允许训完再解释指标为何反常。**

5.4 分类器与对照

方案	说明
阈值法	对每个几何指标设定阈值，作为下界基线
逻辑回归	主方案；多标签采用各类独立判定

方案	说明
SVM	对照方案，核函数取 RBF

多标签采用一类一模型的独立二分类，而非单一 softmax。评估按类别计算精确率、召回率与 F1，并给出宏平均与微平均。

5.5 自建评测集

训练数据来自公开数据集，评测数据必须自建，因为需要配套的原始要求与参考资料。

规模分两档，第一版不追 30 份：

项	第一版	扩至	说明
总数	12 份 / 180 页	20 份 / 300 页	30 份 / 450 页为上限，非目标
真实 AI 生成	4 份	7 份	覆盖至少 3 个生成工具，保留原始提示词
人工模板/课件	5 份	8 份	提供风格对照
质量尚可的样本	3 份	5 份	**负样本，用于计算误报率**

按此收缩的理由有三条：

1. **标注成本按页线性增长，统计收益不是。** 180 页已能给分类别点估计；再加 12 份带来的置信区间收窄，与投入的十余小时不成比例。
2. **时间应投在两处回报更高的地方：**每份的盲标抽页（估计漏报），以及负样本比例。前者决定漏报率是否可信，后者决定误报率是否有分母，两者都比多标 12 份要紧。
3. **缩规模时的取舍顺序固定：**先砍份数，不砍每份页数，不砍负样本比例。若砍到某类缺陷的正例进入个位数，该类退出实验二，只做描述性报告。

第三类容易被忽略：若全部挑选”问题明显”的文件，系统报错时也无法被发现，误报率没有分母。此外，样本须为**可编辑对象**，即每页含多个可解析形状，而非一页一张图片——图片式文件会使结构证据整体归零。

人工标注只针对三类实验区缺陷，标注单元为”页面 + 区域 + 缺陷类型”，分三步完成：先判定存在性（是/否/不确定），再判定严重度，最后记录定位。存在性的一致率通常显著高于严重度，先冻结前者可避免两个维度互相污染。

标注采用机器初筛加人工裁决的方式：先由检测器输出候选问题列表，人工只做确认、否决与补充；同时每份随机抽取两页进行盲标（不看系统输出），用于估计漏报。这既节省时间，也避免了只看到系统已报问题的确认偏差。

5.6 指标与成本口径

实验	对比对象	主指标	次指标
一分类可行性	阈值 / 逻辑回归 / SVM	分类别 F1、PR 曲线	训练与推理耗时
二分层对比	仅规则 / 仅 ML / 分层协同	分类别 F1	**调用次数、token、耗时**
三证据约束	直接问模型 / 证据约束	定位命中率、无依据断言比例	人工复核条数

实验二有一条必须先解决的方法论问题：三类方案覆盖的缺陷类别不同，若在同一测试集上计算总体 F1，分层方案几乎必然最高，但胜出的原因只是覆盖面更广，而非方法更优。这属于覆盖度混淆。

处理办法是：主对比只放在**各方案都声称能检的公共类别**上（留白失衡既可写成阈值规则，也可由几何特征分类器判定，是最合适的对照点）；其余类别以" 方案 × 类别" 矩阵报告覆盖能力；成本与效果按同一单位计算，最后以曲线而非单一数字呈现。

成本口径须固定：调用次数按页计，token 只计输入与输出、不计缓存，规则层记为 0 次调用但注明其开发成本未计入。

6 课程知识映射

课程内容	项目中的落点	对应产出	是否核心
逻辑回归	视觉缺陷多标签分类	实验一主模型	是
SVM	与逻辑回归的分类效果对照	实验一对照组	是
数据可视化	问题分布、执行过程、成本—效果曲线	报告图表与界面	是
本体知识建模	缺陷编码、证据关系、建议知识库	建议模板库、缺陷类别表	是
向量 RAG	参考资料检索与基于证据的追问	完整性核验、追问	可降级
智能体设计	工具编排、按需复核、状态管理	调度层	是

知识建模一项容易被做成形式主义，本项目的落点尽量具体：缺陷类别表的每一行本身就是一个类，其" 首选层""所需证据""建议模板" 是属性，而" 某缺陷需要哪类证据""某证据支持哪些缺陷" 构成关系。报告生成时按图查询建议，而不是写一长串 `if` 分支。

RAG 一项属于可降级模块：参考资料覆盖检查可以在没有向量检索的情况下，用要素抽取加字符串匹配实现；向量检索主要改善” 表述不同但含义相同” 的召回。若时间不足，该模块降级不影响主链路。

7 开发路线

五个阶段，每阶段结束时都有可演示的产物，且不依赖后续阶段。

阶段	内容	阶段产物	通过判据
一基础审查	PPTX 解析、页面渲染、越界与字号规则	可对任意 PPTX 输出带页码与对象信息的报告	5 份样本全部出图，坐标对齐误差小于 2 pt
二智能体最小闭环	路由、冲突判定、按需复核、成本计数	一条能自己决定” 要不要再查一次” 的链路	复核可触发、可计数，冲突能正确降级
三机器学习	特征可提取性核查、数据整理、分类器训练	实验一结果与对照	分类器可运行，有分类别指标与 PR 曲线
四风格分析	PTPS 与 HCI 计算、明细清单	分数、分项、证据页清单	两项指标可复算，明细可追溯到具体页面
五界面与报告	Streamlit 界面、报告生成、追问	上传—审查—复核—报告的完整流程	端到端无人工干预跑通一份 PPT

阶段顺序按依赖关系排，不按工作量排；交付优先级与阶段顺序是两件事。阶段二紧跟阶段一，是刻意的：智能体闭环只需要” 一组规则结论 + 一次复核调用”，既不需要等分类器训好，也不需要等风格指标算完。若把整合排到最后，一旦时间不足，被砍掉的恰好是课程真正评分的那部分——决策链，而不是检测器数量。

最小闭环里的模型调用只承担一件事：对被判定为不确定或存在冲突的单条结论，给出” 成立 / 不成立 / 无法判断” 三选一及一句理由，输出为固定三字段的 JSON。这比实现完整的跨页语义检测便宜一个数量级，却足以让” 按需复核” 真实成立。按此顺序推进，任意时刻中断，交付的仍是一个可演示的完整系统，差别只在覆盖面的宽窄：

- **阶段一结束**：纯规则的结构审查报告，零 API 调用；但没有决策链，不体现智能体。
- **阶段二结束**：检测 → 冲突 → 复核 → 降级 → 报告的完整链路，覆盖 2–3 类缺陷；机器学习与风格指标缺位。
- **阶段三结束**：上述链路加一个有独立测试结果的分类器；风格指标仍缺位。
- **阶段四结束**：再加 PTPS / HCI 与明细；界面仍为命令行输出。
- **阶段五结束**：完整系统。

阶段二结束那一档是本项目的最低可交付线：宁可只检三类但会自己复核，也不要检八类但只会罗列。这一条同时约束砍单顺序——时间不足时先砍阶段四，其次把阶段五降为静态 HTML 报告，阶段一与二不砍。

阶段一有一条前置判断必须在第一天完成：**抽 5 份 PPTX，统计每页的形状数量**。若多数页面只有一个图片对象，说明文件为图片式导出，结构证据整体失效，须当天调整方案（改为以渲染图为主，或补充可编辑样本）。这一步只需十分钟，却决定后续所有假设是否成立。

渲染方案采用 **PowerPoint COM 优先、LibreOffice headless 备选**。前者保真度最高，尤其是中文字体与行距；后者用于交叉验证与环境迁移。需注意：同一份 PPTX 在两条管线下的字体回退与行距算法不同，会直接影响”文字溢出”与”留白失衡”的判定结果。因此标注所用的渲染图与检测所用的渲染图必须来自同一管线，否则测出的是渲染器差异而非文稿质量。

8 风险与已知局限

风险	触发信号	应对
样本为图片式	首日体检发现多数页面仅一个图片对象	补充可编辑样本；或将规则层改测渲染图可判的属性，重写假设
渲染字体缺失	抽查出现方块字或字体替换	安装缺失字体；否则更换字体族并在报告中声明
SlideAudit 标签不覆盖目标类别	标签清单无”留白”对应项	更换目标类别，或改用自建样本训练，结论降级
SlideAudit 特征不可提取	核查表出现”不可得”项	该类移出实验一，改由规则或自建样本验证；不先训练再解释
CLIP 对几何属性不敏感	消融显示仅视觉特征时 F1 显著低	已有应对：几何特征为主，视觉特征为辅；如实报告消融结果
分类器效果不达预期	测试集 F1 低于 0.40	并列报告阈值法与分类器，结论写”在该特征集与样本量下，监督学习未显著优于阈值法”
评测样本标注滞后	阶段三时完成度不足 12 份	按 5.5 节的第一版规模先跑，不缩减每份页数与负样本比例
时间不足	阶段二结束仍未跑通闭环	按第 7 节的中断优先级：保一、二（决策链），砍四（风格指标），五退为静态 HTML 报告
模型 API 不可用或限流	复核调用连续失败	复核降级为”标记待核实 + 记录失败次数”，不伪造结论，成本栏注明

三条已知局限需要写在报告的显著位置，而非藏在附录：

其一，样本量有限。第一版 12 份、约 180 页，视进度扩至 20 份、约 300 页。这足以支撑分类别的点估计与方案间排序，不足以支撑精细的置信区间；报告只给点估计并明确样本规模，不外推为普遍结论。

其二，渲染管线的偏差未被完全消除。无论选择哪条管线，渲染结果与用户在 PowerPoint 中看到的画面都会存在差异，这部分差异无法从指标中分离。

其三，PTPS 与 HCI 的阈值未校准。当前权重与阈值均为工程默认值，未经数据拟合。校准与否只影响分数高低，不影响”该指标可计算”这一事实——这与”AI 生成概率”有本质区别：后者缺少基线即不成立，前者缺少校准只是不精确。另需重申 4.3.1 的边界：分数只表示结构规律性，不表示设计质量，规范模板同样会得高分。

9 预期成果

9.1 系统层面

一套可本地运行的审查系统，输入 PPTX 与可选的原始要求、参考资料，输出交互式审查报告，包含：按页问题清单、证据定位、风险分级、可执行建议、PTPS 与 HCI 分数及明细、以及本次审查的模型调用成本。

9.2 实验层面

三组可复现的对照结果：分类可行性（阈值 / 逻辑回归 / SVM，覆盖留白失衡与布局拥挤两类）、分层对比（仅规则 / 仅 ML / 分层协同，含成本）、证据约束（有 / 无证据绑定的结论质量）。以及特征消融结果（几何 / 视觉 / 拼接）。

9.3 方法层面

若实验支持，本项目可以给出一个可复用的判断：**在演示文稿质量审查中，不同缺陷类型的最优检测层不同，且这一差异可由证据可得性解释。**若实验结果不支持，则如实报告负结果并分析原因——这同样是有效的结论。

9.4 一句话

这个项目的下限由工程保证（渲染通即稳），上限由评测集的标注质量决定，第一印象由界面决定。三者不能互相替代。

参考文献

[1] Zhang Z, Chen R, Zhong M, Wobbrock J O. SlideAudit: A Dataset and Taxonomy for Automated Evaluation of Presentation Slides[C]//Proceedings of the 38th Annual ACM Symposium on User Interface Software and Technology (UIST ’25). ACM, 2025. DOI: 10.1145/3746059.3747736.

[2] Zheng H, Guan X, Kong H, Zheng J, Zhou W, Lin H, Lu Y, He B, Han X, Sun L. PPTAgent: Generating and Evaluating Presentations Beyond Text-to-Slides[J]. arXiv preprint arXiv:2501.03936, 2025.（PPTEval 评测框架随本文提出）

[3] Chen X-S, Zhu J, Li P, Wang H, Yang S, Guo M-H. PresentBench: A Fine-Grained Rubric-Based Benchmark for Slide Generation[J]. arXiv preprint arXiv:2603.07244, 2026.

[4] Lu Y, Knearem T, Dutta S, Blass J, Kliman-Silver C, Bentley F. AI Is Not Enough: A Hybrid Technical Approach to AI Adoption in UI Linting With Heuristics[C]//Extended Abstracts of the CHI Conference on Human Factors in Computing Systems (CHI EA '24). ACM, 2024: Article 501. DOI: 10.1145/3613905.3637135.

[5] Radford A, Kim J W, Hallacy C, et al. Learning Transferable Visual Models From Natural Language Supervision[C]//Proceedings of the 38th International Conference on Machine Learning (ICML). PMLR, 2021: 8748–8763.

[6] Platt J. Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods[M]//Advances in Large Margin Classifiers. MIT Press, 1999: 61–74.

[7] Guo C, Pleiss G, Sun Y, Weinberger K Q. On Calibration of Modern Neural Networks[C]//Proceedings of the 34th International Conference on Machine Learning (ICML). PMLR, 2017: 1321–1330.

数据集与代码资源：

[8] SlideAudit 数据集与代码. https://github.com/zhuohaouw/SlideAudit（CC BY 4.0）

[9] PresentBench 数据集. https://huggingface.co/datasets/PresentBench/PresentBench（任务指令与 checklist 采用 CC BY-NC 4.0）

附录 A 统一结论记录的核心字段

字段	类型	说明
finding_id	string	全局唯一
slide_index	int	从 1 开始
defect_code	string	缺陷编码
detector	string	检测器标识与版本
severity	enum	最高 / 严重 / 次要 / 提示
status	enum	已确认 / 可能 / 待核实
confidence	float	0 至 1，语义随来源变化；跨来源不可直接比较（见 4.7.1）

字段	类型	说明
confidence_source	enum	规则 / 模型概率 / 模型自评 / 融合；决定 confidence 的解释方式
bbox	float[4]	归一化坐标，页级缺陷为空
evidence	array	至少一条，空证据不允许
rationale	string	面向用户的一句话解释
suggestion	string	可分三级，须指明对象与方向
cost_calls / cost_tokens	int	产生该结论的调用成本
detectors_checked	array	该单元被哪些检测器检查过
conflict_detectors	array	明确判定不存在的检测器

附录 B 术语表

术语	含义
证据族	判定一类缺陷所需的最小证据类型：结构、视觉、语义、要求
检测路由	由缺陷类别表指定的执行层，与前缀无关
判决 Claim	检测器的原始输出，含”存在”与”不存在”两种取值
结论 Finding	融合后的结论原子，只有”存在”的判决会转为结论
PTPS	单页模板化特征分，页内指标
HCI	整份同质化指数，页间指标
按需复核	依据置信度与冲突决定是否追加一次模型调用的决策机制，阈值按来源分设
概率校准	把分类器的原始输出映射为接近真实频率的概率，方法如 Platt 缩放
序数置信度	大模型自评的高 / 中 / 低标签，属语言判断而非概率，不可与分类器概率比较
覆盖度混淆	因方案覆盖类别不同而导致的总体指标不可比